Perbandingan Kinerja Algoritma Regresi Linear dan SVR dalam Memprediksi Harga Rumah

Fajar Nurdiansyah*[1], Yuldan Nur Addinsyah[2], Diaz Rifqi Munggaran [3]
[1,2, 3]Informatika, Universitas Siliwangi, Tasikmalaya
e-mail: *[1]227006077@student.unsil.ac.id, [2]227006091@student.unsil.ac.id,
[3]227006087@student.unsil.ac.id

Abstrak

Prediksi harga rumah yang akurat sangat penting dalam mendukung pengambilan keputusan bagi pembeli, penjual, maupun pengembang properti. Penelitian ini membandingkan kinerja algoritma Regresi Linear dan Support Vector Regression (SVR) dalam memprediksi harga rumah di daerah Tebet, Jakarta, menggunakan dataset dari Kaggle. Proses penelitian meliputi tahap preprocessing data, pembagian data menjadi data latih dan uji, serta pemodelan menggunakan pipeline dan hyperparameter tuning. Evaluasi model dilakukan menggunakan metrik RMSE dan R^2. Hasil menunjukkan bahwa SVR memiliki performa lebih baik dibandingkan Regresi Linear, dengan RMSE sebesar 0.0696 dan R^2 sebesar 0.9825, sedangkan Regresi Linear mencatatkan RMSE sebesar 0.1296 dan R^2 sebesar 0.9395. Temuan ini menegaskan bahwa SVR lebih efektif dalam menangani hubungan non-linear yang kompleks pada data harga rumah. Kesimpulannya, SVR menjadi pilihan yang lebih unggul dalam membangun model prediksi harga rumah yang akurat.

Kata kunci—, Regresi Linear, Support Vector Regression, Harga Rumah, Prediksi

Abstract

Accurate house price prediction is crucial for supporting decision-making by buyers, sellers, and property developers. This study compares the performance of Linear Regression and Support Vector Regression (SVR) algorithms in predicting house prices in the Tebet area, Jakarta, using a dataset from Kaggle. The research process includes data preprocessing, splitting data into training and testing sets, and modeling using a pipeline and hyperparameter tuning. Model evaluation is conducted using RMSE and R^2 metrics. The results show that SVR outperforms Linear Regression, achieving an RMSE of 0.0696 and R^2 of 0.9825, while Linear Regression records an RMSE of 0.1296 and R^2 of 0.9395. These findings confirm that SVR is more effective in handling complex non-linear relationships in housing price data. In conclusion, SVR is a more superior choice for building accurate house price prediction models.

Keywords— *Linear Regression, Support Vector Regression, House Prices, Prediction*

1. PENDAHULUAN

Pentingnya memahami perkembangan harga rumah di area perkotaan semakin menjadi perhatian utama, terutama di daerah yang sedang berkembang pesat seperti Tebet, Jakarta. Rumah tidak hanya merupakan kebutuhan pokok, tetapi juga investasi jangka panjang yang dapat meningkat nilainya seiring waktu [1]. Dengan meningkatnya permintaan properti rumah, prediksi harga rumah yang akurat menjadi suatu hal yang sangat berharga bagi para pembeli, penjual, maupun pengembang properti. Oleh karena itu, menggunakan teknik prediksi yang efektif, seperti

algoritma regresi, dapat membantu memberikan perkiraan yang lebih jelas mengenai harga rumah di masa depan.

Dalam penelitian ini, dua algoritma yang sering digunakan untuk prediksi harga rumah, yaitu *Regresi Linear* dan *Support Vector Regression* (SVR), dibandingkan kinerjanya dalam memprediksi harga rumah di Tebet. Regresi Linear merupakan metode statistik yang digunakan untuk mengidentifikasi hubungan linear antara variabel dependen (harga rumah) dan beberapa variabel independen di mana dalam kasus ini seperti luas bangunan, luas tanah, jumlah kamar tidur, dan fasilitas lainnya [2]. Regresi Linear sering dipilih karena kesederhanaannya dalam model dan kemudahan interpretasi hasil. Namun, meskipun sederhana, regresi linear mungkin kurang efektif ketika data menunjukkan hubungan yang lebih kompleks.

Sebaliknya, SVR, yang merupakan pengembangan dari *Support Vector Machine* (SVM), digunakan untuk memodelkan hubungan non-linear antara variabel. Algoritma ini sering kali lebih mampu menangani data yang memiliki fluktuasi tinggi dan ketergantungan yang kompleks. SVR bekerja dengan mencari hyperplane terbaik untuk memisahkan data, dengan tujuan untuk meminimalkan kesalahan prediksi [3]. Dengan kemampuan SVR untuk menangani data non-linear, banyak yang percaya bahwa SVR dapat memberikan hasil prediksi yang lebih akurat pada dataset dengan hubungan yang lebih kompleks, seperti data harga rumah yang dipengaruhi oleh berbagai faktor.

Penelitian sebelumnya telah menunjukkan efektivitas kedua algoritma dalam memprediksi harga rumah. Misalnya, penelitian oleh Saiful, Andryana & Gunaryati (2021) menggunakan Regresi Linear untuk memprediksi harga rumah dengan akurasi yang mencapai 88% [4]. Di sisi lain, penelitian oleh Almahdy & Pradnya (2024) menggunakan SVR dengan fungsi kernel RBF, yang terbukti lebih baik dalam memprediksi harga rumah dengan kesalahan prediksi yang lebih kecil, yaitu RMSE sebesar 11.71% [3]. Dengan hasil ini, SVR menunjukkan kemampuannya dalam menangani ketidaklinieran dan kompleksitas data yang ada. Sementara penelitian Kurniawan, Rahaningsih, & Suprapti (2024) yang menggunakan Regresi Linear dan K-Nearest Neighbor (KNN) dalam memprediksi harga rumah di kawasan Cirebon menunjukkan bahwa kesalahan relatif untuk regresi linier mencapai 71,95% dengan margin kesalahan 82,63%, sementara untuk k-nearest neighbor tercatat 30,95% dengan margin kesalahan 29,87% [5].

Masalah yang dihadapi dalam prediksi harga rumah di Tebet mencakup variabel-variabel penting seperti lokasi yang strategis, luas tanah, fasilitas di sekitar rumah, serta usia bangunan yang memengaruhi harga pasar. Oleh karena itu, penelitian ini akan menguji kedua algoritma untuk melihat bagaimana masing-masing algoritma menangani faktor-faktor tersebut dan seberapa baik prediksi yang dapat dihasilkan. Dengan membandingkan akurasi keduanya melalui pengujian RMSE (*Root Mean Squared Error*) dan R^2, diharapkan dapat diperoleh pemahaman yang lebih baik mengenai kinerja masing-masing algoritma dalam konteks ini [5].

Melalui perbandingan ini, diharapkan dapat ditemukan model yang lebih efisien dan akurat untuk membantu para pihak yang terlibat dalam pasar properti, terutama dalam membuat keputusan yang lebih cerdas mengenai harga rumah.

2. METODE PENELITIAN

Penelitian ini dilakukan dengan tujuan untuk membandingkan kinerja algoritma regresi linear dan SVR dalam memprediksi harga rumah. Adapun alur penelitian yang digunakan dalam penelitian ini agar dapat mencapai tujuan tersebut adalah sebagaimana ditunjukkan pada Gambar 1 berikut:

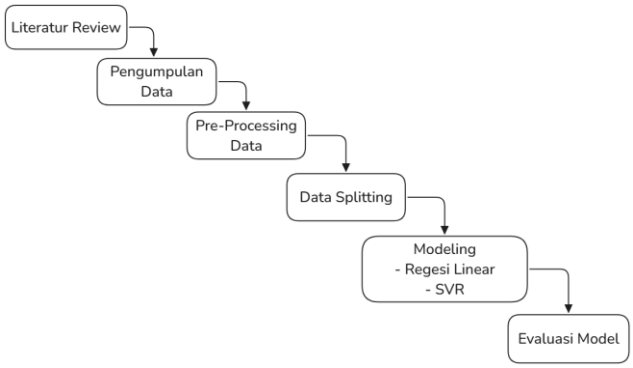

Gambar 1. Alur Penelitian

2.1 Literatur Review

Langkah pertama dalam penelitian ini adalah melakukan kajian literatur yang relevan untuk memperoleh pemahaman yang lebih mendalam tentang teori yang ada serta perkembangan terkini dalam bidang yang diteliti. Kajian literatur ini berfungsi sebagai dasar untuk mengidentifikasi metode yang sudah ada dan memberikan perspektif dalam perbandingan antara algoritma regresi linear dan SVR Berikut beberapa review hasil studi literatur terkait dengan penelitian yang menerapkan regresi linear dan SVR untuk prediksi harga rumah:

Pertama, Penelitian oleh Hallana dan Fajri (2025) membangun model prediksi harga rumah menggunakan algoritma regresi linier dengan dataset yang diperoleh dari Kaggle mengenai harga rumah di Ames, Amerika Serikat. Data sebanyak 1.460 entri diproses melalui tahapan pra-pemrosesan yang mencakup penanganan data hilang, outlier, dan standarisasi fitur dengan StandardScaler. Evaluasi model dilakukan dengan metrik R-squared (R^2) dan Root Mean Squared Error (RMSE), menghasilkan nilai R^2 sebesar 0,81 dan RMSE sebesar 35.830,40, menunjukkan bahwa regresi linier cukup efektif dalam memodelkan hubungan antara fitur-fitur seperti OverallQual, GrLivArea, dan harga rumah [6].

Kedua, dalam penelitian oleh Lumbanraja et al. (2021), SVR digunakan untuk memprediksi harga rumah di Bandar Lampung. Dataset terdiri dari 51 data dengan 33 variabel, dan digunakan tiga jenis kernel: Linear, Polynomial, dan Gaussian (RBF). Hasil evaluasi menunjukkan bahwa kernel Polynomial memberikan hasil terbaik dengan nilai R^2 sebesar 95,99%, diikuti oleh kernel Linear (90,99%) dan Gaussian (81,43%). Hasil ini mengindikasikan bahwa SVR, khususnya dengan kernel non-linear, lebih akurat dibandingkan regresi linear dalam memprediksi harga rumah [7].

Ketiga, penelitian oleh Aenul Fuadah et al. (2024) di Kabupaten Bandung menggunakan metode Multiple Linear Regression (MLR) untuk memprediksi harga rumah. Dengan menggunakan dataset dari situs Kaggle, mereka memperoleh R^2 sebesar 0.69 dan RMSE 694.18, menunjukkan bahwa model regresi linier mampu memberikan prediksi yang cukup akurat meskipun terdapat fluktuasi harga rumah yang dipengaruhi oleh banyak faktor seperti lokasi dan kondisi bangunan [8].

Terakhir, penelitian yang dilakukan oleh Anggun Aulia Bastian et al. (2024) mengenai prediksi harga rumah menggunakan Support Vector Regression (SVR) di Kabupaten Karawang menunjukkan bahwa SVR dapat mengatasi fluktuasi harga yang lebih kompleks. Dalam penelitian ini, SVR menunjukkan RMSE sebesar 234.257 dan MAPE sebesar 21%, yang lebih unggul dibandingkan dengan Linear Regression, yang menghasilkan RMSE sebesar 249.086 dan MAPE sebesar 22% [9].

2.2 Pengumpulan Data

Data yang diperoleh bukan merupakan data primer hasil survei atau observasi peneliti pribadi, melainkan data sekunder yang diperoleh dari situs *Kaggle* dengan tautan

https://www.kaggle.com/datasets/wisnuanggara/daftar-harga-rumah. Dataset berisi daftar harga rumah di kawasan Tebet Jakarta yang berjumlah 1010 data dengan 8 kolom atribut.

2.3 Preprocessing

Tahap preprocessing merupakan langkah krusial dalam pengolahan data, karena bertujuan untuk meningkatkan kualitas data sehingga dapat dimanfaatkan secara optimal. Proses ini diawali dengan data cleaning, yaitu menghapus variabel-variabel yang dianggap tidak relevan. Selanjutnya dilakukan pemeriksaan terhadap missing value, data duplikat, outlier, dan noise. Setelah proses pembersihan selesai, tahap berikutnya adalah data transformation. Pada bagian ini, data bertipe objek diubah menjadi tipe numerik (integer) menggunakan teknik label encoding. Selain itu, dilakukan pula penyesuaian pada variabel price dengan membaginya per satu juta untuk mempermudah interpretasi. Langkah terakhir dalam preprocessing adalah data normalization, yang dalam penelitian ini diterapkan menggunakan metode MinMaxScaler.

2.4 Data Splitting

Tahapan splitting data 80:20 adalah proses membagi dataset menjadi dua bagian utama: data latih (training data) dan data uji (testing data) dengan perbandingan 80% untuk pelatihan dan 20% untuk pengujian.

2.5 Model Regresi Linear

Regresi linear merupakan suatu metode analisis statistik yang digunakan untuk memodelkan hubungan antara satu variabel dependen dengan satu atau lebih variabel independen. Tujuannya adalah untuk memprediksi nilai variabel dependen berdasarkan nilai variabel independen, serta memahami besarnya pengaruh masing-masing variabel bebas.

Bentuk umum model regresi linear berganda dapat dituliskan sebagai berikut:

$$Y = \beta 0 + \beta 1X1 + \beta 2X2 + \cdots + \beta kXk + \varepsilon$$

Keterangan:

- Y = variabel dependen (respon)
- X1,X2,...,Xk = variabel independen (prediktor)
- β0 = intersep atau konstanta
- β1,β2,...,βk= koefisien regresi
- ε = galat (error), diasumsikan berdistribusi normal dengan rata-rata nol dan variansi konstan

2.6 Model Suport Vector Regression

Model *Support Vector Regression* merupakan perluasan dari *Support Vector Machine* (SVM) yang dirancang untuk menyelesaikan masalah regresi, bukan klasifikasi. Secara cara kerja, SVR memiliki prinsip yang sama dengan SVM yaitu dengan menemukan solusi optimal dengan memaksimalkan margin namun untuk memetakan hubungan input-output yang sifatnya kontinu [10].

Model SVR bertujuan untuk menemukan fungsi prediksi f(x) yang sesederhana mungkin, toleran terhadap kesalahan kecil (dalam margin ϵ), dan meminimalkan penalti untuk kesalahan besar (di luar margin). SVR memiliki fungsi prediksi linear sebagai berikut:

$$f(x) = \omega^T x + b$$

Keterangan:

- ω = bobot (arah garis regresi)
- b = bias (pergerakan vertikal)

Masalah SVR diformulasikan sebagai optimisasi konveks, yang bertujuan meminimalkan dua hal secara bersamaan: kompleksitas model (diukur dari besar kecilnya bobot model, agar model tetap sederhana dan tidak overfitting) dan total penalti dari kesalahan prediksi yang melampaui ε-tube. Dalam proses pelatihan ini, tidak semua data digunakan secara langsung untuk menentukan fungsi regresi akhir. Hanya data-data yang berada di luar ε-tube—yang mengalami kesalahan prediksi lebih dari ε—yang akan berperan dalam menentukan model. Data-data tersebut disebut sebagai support vectors.

Untuk menangani hubungan non-linear antara variabel input dan output, SVR menerapkan teknik yang disebut kernel trick. Dengan cara ini, data yang awalnya tidak linier dapat dipetakan ke ruang berdimensi lebih tinggi menggunakan fungsi kernel (seperti RBF, polynomial, atau sigmoid), sehingga hubungan non-linear di ruang asal dapat dimodelkan secara linear di ruang tersebut. Ini memungkinkan SVR menangani berbagai jenis pola data, baik linier maupun non-linier, secara fleksibel dan efektif.

Adapun kelebihan yang dimiliki dari model SVR yaitu memiliki akurasi tinggi dan generalisasi yang baik pada data yang belum pernah dilihat sebelumnya, tidak tergantung pada dimensi fitur sehingga akan menjadi efektif meskipun jumlah fitur yang tinggi, dan dapat menggunakan berbagai jenis kernel sesuai kebutuhan data. Namun, model SVR tetap memiliki kekurangan di mana pemilihan parameter sangat sensitif dan butuh pencarian teliti seperti GridSearch, kurang efisien pada dataset besar karena proses optimasi memakan waktu, dan sulit diinterpretasikan terutama saat menggunakan kernel non-linear.

2.7 Evaluasi Model

Pada tahapan ini, data latih yang sudah dimodelkan akan dilakukan evaluasi tingkat keakuratannya pada data uji. Beberapa framework untuk evaluasi model regresi yaitu antara lain RMSE, MAE, MSE, R^2 Score, dll. RMSE (*Root Mean Squared Error*) mengukur rata-rata kesalahan kuadrat antara nilai-nilai prediksi dan nilai aktual. RMSE menghitung seberapa jauh (secara kuadrat) prediksi model menyimpang dari kenyataan. RMSE sangat sensitif terhadap error yang besar (outliers), karena kesalahan dikuadratkan terlebih dahulu sebelum dirata-ratakan [11]. Dalam jurnal, RMSE dihitung dengan asumsi bahwa:

- Distribusi error bersifat unbiased (rata-rata error = 0),
- Error mengikuti distribusi normal (Gaussian).

Misalkan kita memiliki n buah error (perbedaan antara nilai observasi dan nilai model) yang dinotasikan sebagai ei, maka RMSE dihitung dengan rumus:

$$\sqrt{\frac{1}{n}\sum_{i=1}^{n} e_i^2}$$

Dengan:

- n = jumlah data,
- ei = error dari sampel ke-i (yaitu prediksi − observasi).

Framework evaluasi model regresi yang kedua yaitu R^2 Score yang merupakan ukuran proporsi variasi total dalam variabel dependen (y) yang dapat dijelaskan oleh model regresi. Dalam bentuk paling umum, R^2 mengukur seberapa banyak peningkatan dalam model prediktif dibandingkan dengan model acuan sederhana—biasanya model yang hanya memuat nilai rata-rata (mean-only model). R^2 atau koefisien determinasi dijelaskan secara mendalam sebagai

ukuran goodness-of-fit, yakni seberapa baik suatu model regresi menjelaskan variasi dalam data dibandingkan dengan model acuan (reference model) [12].
Secara umum:

$$R^2 = 1 - \frac{RSSmodel}{TSS}$$

Di mana:

- $RSSmodel = \sum(yi - \hat{y}i)^2$= residual sum of squares dari model yang digunakan
- $TSS = \sum(yi - \bar{y}i)^2$= total sum of squares dari model referensi (biasanya model hanya dengan intercept, yaitu y = μ + ε)

R^2 bernilai:

- 1 jika model sempurna,
- 0 jika model tidak lebih baik dari rata-rata,
- < 0 jika model lebih buruk dari hanya menebak rata-rata.

3. HASIL DAN PEMBAHASAN

3.1 Pengumpulan Data

Dataset harga dirumah diperoleh dari website *Kaggle.com* yang terdiri dari 2 jenis daftar harga rumah Jakarta Selatan dan Tebet. Dari 2 daftar harga tersebut, peneliti menggunakan dataset harga rumah di Tebet Jakarta untuk dilakukan prediksi harga menggunakan algoritma Regresi Linear dan *Support Vector Regression* (SVR). Dataset terdiri dari 1010 baris data dan 8 fitur rumah meliputi NO sebagai nomor data, NAMA RUMAH berarti judul, HARGA, LB berarti jumlah luas bangunan, LT berarti jumlah luas tanah, KT berarti jumlah kamar tidur, KM berarti jumlah kamar mandi, dan GRS berarti jumlah kapasitas mobil dalam garasi.

Tabel 1. Dataset Harga Rumah

NO	NAMA RUMAH	HARGA	LB	LT	KT	KM	GRS
1	Rumah Murah Hook Tebet Timur, Tebet, Jakarta S...	3800000000	220	220	3	3	0
2	Rumah Modern di Tebet dekat Stasiun, Tebet, Ja...	4600000000	180	137	4	3	2
3	Rumah Mewah 2 Lantai Hanya 3 Menit Ke Tebet, T...	3000000000	267	250	4	4	4
4	Rumah Baru Tebet, Tebet, Jakarta Selatan	430000000	40	25	2	2	0
5	Rumah Bagus Tebet komp Gudang Peluru lt 350m, ...	9000000000	400	355	6	5	3
...	...	...	...	...	...	...	...
1006	Rumah Strategis Akses Jalan 2mobil Di Menteng ...	9000000000	450	550	10	10	3
1007	Tebet Rumah Siap Huni Jln 2 Mbl Nyaman	4000000000	160	140	4	3	2
1008	Di Kebun Baru Rumah Terawat, Area Strategis	4000000000	139	230	4	4	1
1009	Dijual Cepat Rumah Komp Depkeu Dr Soepomo Tebe...	19000000000	360	606	7	4	0

1010	Dijual Rumah Kokoh Di Gudang Peluru	10500000000	420	430	7	4	2

3.2 Preprocessing

Pada tahapan ini, data yang sudah dikumpulkan melalui situs Kaggle dilakukan preprocessing dengan melakukan penanganan pada data kosong,duplikat, dan outlier.

1. Tidak ada data yang kosong.
2. Terdapat 43 data duplikat sehingga akan dilakukan penanganan dengan cara menghapusnya.
3. Pada kolom harga, luas bangunan, dan luas tanah terdapat outlier sehingga perlu diatasi dengan menggabungkan cara log transformation dan dengan Teknik quantile.

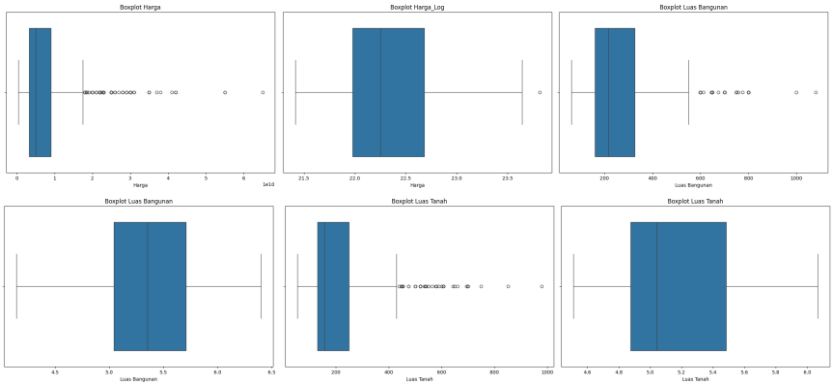

Gambar 2. Visualisasi Transformasi Data dengan Boxplot

4. Melakukan feature engineering pada kolom Jumlah kamar tidur menjadi kamar tidur <= 4 sehingga value_counts terdistribusi rata.
5. Melakukan feature engineering pada kolom jumlah kamar mandi menjadi kamar mandi<= 3 sehingga value_counts terdistribusi rata.
6. Melakukan feature engineering pada kolom jumlah garasi menjadi garasi > 1 sehingga value_counts terdistribusi rata.

3.3 Splitting Data

Setelah data selesai dilakukan preprocessing, tahap selanjutnya adalah membagi data menjadi data latih dan data uji. Dataset dipisahkan ke dalam dua variable yaitu variabel X yang berisi semua data fitur rumah dan variable y berisi kolom target yaitu HARGA_log. Kemudian, setiap variable X dan y dibagi menjadi data latih dan data uji dengan perbadingan 80:20, di mana 80% data digunakan untuk *training* dan 20% data digunakan untuk *testing*.

3.4. Pemodelan dengan Regresi Linear

Setelah dilakukan splitting, langkah selanjutnya yaitu melakukan pemodelan dengan model linear regresi. Sebelum dilakukan pemodelan, data yang sudah dilakukan preprocessing akan melalui pipeline di mana data akan melalui proses scaling dan training secara berurutan dalam satu alur. Standarscaler akan menstandarkan fitur (mean=0, std=1) dan kemudian akan dimasukkan ke dalam model regresi linear. Model akan dilakukan hyperparameter tuning dengan parameter yang akan diuji yaitu:

1. lr__fit_intercept: [True, False] : apakah model harus menghitung intersep (True) atau tidak (False).

2. lr__positive: [False, True] : jika True, maka semua koefisien regresi harus positif (biasa dipakai untuk interpretasi bisnis/logika).

Hyperparameter tuning dilakukan dengan memanfaatkan GridSearchCV yang akan mencoba semua kombinasi parameter dari linreg_params sebanyak 5 fold CV.

3.4. Pemodelan dengan SVR

Setelah dilakukan proses splitting data, langkah selanjutnya adalah melakukan pemodelan menggunakan model Support Vector Regression (SVR). Sebelum pemodelan dilakukan, data hasil preprocessing akan diproses melalui pipeline, di mana data akan melalui tahapan scaling dan pelatihan model secara terintegrasi. Proses scaling dilakukan menggunakan StandardScaler, yang akan menstandarkan fitur (mean = 0, standar deviasi = 1), sebelum data dimasukkan ke dalam model SVR.

Untuk meningkatkan performa model, dilakukan proses hyperparameter tuning dengan parameter yang diuji sebagai berikut:

1. svr__kernel: ["rbf"] – menggunakan kernel radial basis function yang cocok untuk masalah regresi non-linear.
2. svr__C: [0.01, 0.1, 1] – parameter regulasi, yang mengontrol trade-off antara error training dan margin.
3. svr__epsilon: [0.1, 0.2, 0.5] – menentukan batas toleransi dalam zona margin di mana tidak ada penalti diberikan.
4. svr__gamma: ['scale', 0.1, 1] – parameter kernel yang menentukan seberapa jauh pengaruh satu titik data.

3.5 Evaluasi

Hasil evaluasi prediksi harga rumah menggunakan dua model, yaitu Linear Regression dan Support Vector Regression (SVR). Model Linear Regression menunjukkan performa yang sangat baik dengan parameter terbaik berupa intercept yang disertakan dalam perhitungan dan koefisien regresi yang tidak dibatasi untuk bernilai positif. Model ini memiliki nilai cross-validation score (negatif MSE) sebesar -0.0153, RMSE sebesar 0.1296, dan skor R2 sebesar 0.9395. Artinya, model ini mampu menjelaskan sekitar 93.95% variabilitas harga rumah dengan kesalahan prediksi rata-rata yang relatif kecil, meskipun masih ada ruang untuk perbaikan. Hasil evaluasi model regresi linear terlampir pada gambar 3.

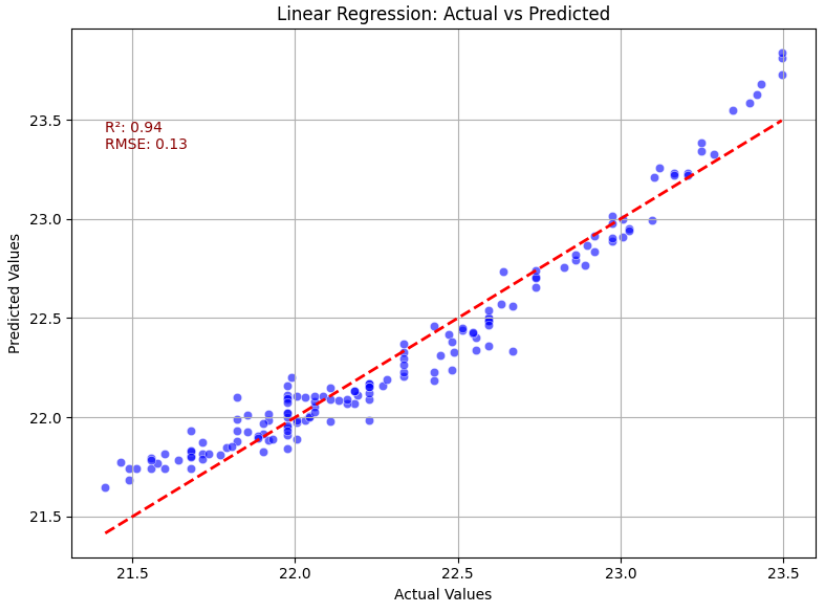

Gambar 3 Hasil Evaluasi Model Regresi Linear

Sementara itu, model SVR dengan parameter C=1, epsilon 0.1, gamma 0.1, dan kernel RBF menunjukkan performa yang lebih unggul dibandingkan Linear Regression. Nilai cross-validation score (negatif MSE) pada SVR adalah -0.0054, RMSE sebesar 0.0696, dan skor R2 mencapai 0.9825. Hal ini mengindikasikan bahwa model SVR dapat menjelaskan lebih dari 98% variabilitas harga rumah dengan tingkat kesalahan prediksi yang lebih rendah, sehingga menghasilkan prediksi yang lebih akurat. Dengan demikian, SVR terbukti lebih efektif dalam menangani data harga rumah dan memiliki keunggulan dalam hal akurasi dibandingkan dengan Linear Regression. Hasil evaluasi model SVR terlampir dalam Gambar 4.

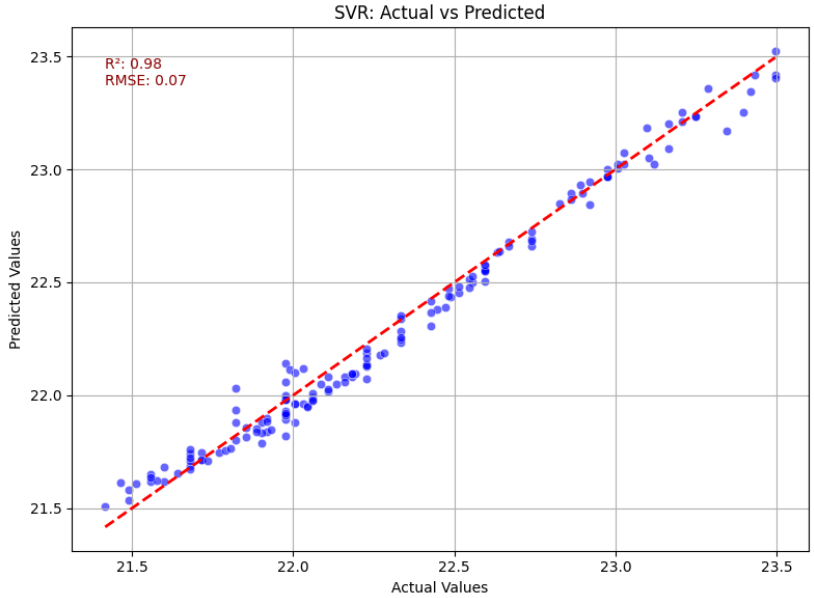

Gambar 4 Hasil Evaluasi Model SVR

Tabel 2. Perbandingan Evaluasi Model

Metode	Parameter Utama	Cross-Validation Score (Negatif MSE)	RMSE	R^2 Score	Keterangan
Linear Regression	-Intercept disertakan -Koefisien tidak dibatasi positif	-0.0153	0.1296	0.9395	Cukup akurat menjelaskan ±93.95% variabilitas harga rumah
Support Vector Regression (SVR)	C = 1 Epsilon = 0.1 Gamma = 0.1 Kernel = RBF	-0.0054	0.0696	0.9825	Lebih akuratmenjelaskan >98% variabilitas harga rumah

4. KESIMPULAN

Penelitian ini berhasil membandingkan kinerja dua algoritma prediksi harga rumah, yaitu Regresi Linear dan Support Vector Regression (SVR), dengan menggunakan dataset harga rumah di Tebet, Jakarta. Hasil evaluasi menunjukkan bahwa SVR memiliki kinerja yang lebih unggul dibandingkan Regresi Linear, dengan nilai RMSE sebesar 0.0696 dan R^2 sebesar 0.9825, yang

berarti mampu menjelaskan lebih dari 98% variabilitas harga rumah. Sementara itu, Regresi Linear mencatatkan nilai RMSE sebesar 0.1296 dan R^2 sebesar 0.9395. Keunggulan SVR terletak pada kemampuannya dalam menangani hubungan non-linear dan kompleks antar variabel, menjadikannya lebih akurat dalam prediksi harga rumah dibandingkan model linear yang cenderung sederhana dan lebih cocok untuk hubungan linier. Temuan ini mengindikasikan bahwa untuk data harga rumah yang kompleks, SVR merupakan pilihan algoritma yang lebih tepat.

5. SARAN

Penelitian selanjutnya disarankan untuk mengeksplorasi model prediksi lain yang berbasis machine learning seperti Random Forest, Gradient Boosting, atau Neural Network untuk melihat kemungkinan peningkatan akurasi prediksi lebih lanjut. Selain itu, penggunaan dataset yang lebih besar dan beragam dari berbagai wilayah dapat meningkatkan generalisasi model. Perlu juga dilakukan eksplorasi terhadap teknik feature engineering yang lebih kompleks serta pengujian terhadap kombinasi berbagai jenis kernel pada SVR untuk memaksimalkan kinerjanya. Dengan pengembangan tersebut, diharapkan model prediksi yang dihasilkan dapat semakin akurat dan aplikatif dalam dunia nyata.

UCAPAN TERIMA KASIH

Peneliti mengucapkan terimakasih kepada setiap elemen yang telah membantu dan memberikan arahan selama proses penelitian berlangsung. Terutama kepada dosen pengampu mata kuliah Rekayasa Data Ir. Rianto yang senantiasa memberikan saran seputar progres penelitian.

DAFTAR PUSTAKA

[1] R. N. T. Siregar, V. Sitorus and W. P. Ananta, "Analisis Prediksi Harga Rumah di Bandung Menggunakan Regresi Linear Berganda," *Journal of Creative Student Research,* vol. 1, no. 6, pp. 395-404, 2023.

[2] N. Kusumawati, F. Marisa and I. D. Wijaya, "PREDIKSI KURS RUPIAH TERHADAP DOLLAR AMERIKA DENGAN MENGGUNAKAN METODE REGRESI LINEAR," *Jurnal Informatika Merdeka Pasuruan,* vol. 2, no. 3, pp. 45-56, 2017.

[3] R. F. Almahdy and W. M. Pradnya D, "Prediksi Harga Rumah Di Kabupaten Bantul Menggunakan Algoritma Support Vector Regression," *Jurnal Teknik Informatika dan Sistem Informasi,* vol. 11, no. 2, pp. 152-165, 2024.

[4] A. Saiful, S. Andryana and A. Gunaryati, "Prediksi Harga Rumah Menggunakan Web Scrapping Dan Machine Learning Dengan Algoritma," *Jurnal Teknik Informatika dan Sistem Informasi,* vol. 8, no. 1, pp. 41-50, 2021.

[5] I. Kurniawan, N. Rahaningsih and T. Suprapti, "IMPLEMENTASI ALGORITMA REGRESI LINIER DAN K-NEAREST NEIGHBOR UNTUK PREDIKSI HARGA RUMAH," *Jurnal Mahasiswa Teknik Informatika,* vol. 8, no. 1, pp. 1187-1193, 2024.

[6] R. R. Hallan and I. N. Fajri, "Prediksi Harga Rumah menggunakan Machine Learning Algoritma Regresi Linier," *Jurnal Teknologi Dan Sistem Informasi Bisnis,* vol. 7, no. 1, pp. 57-62, 2025.

[7] F. R. Lumbanraja, R. A. Saputra, K. Muludi, A. Hijriani and A. Junaidi, "Implementasi Support Vector Machine dalam Memprediksi Harga Rumah pada Perumahan di Kota Bandar Lampung," *Jurnal Pepadun,* vol. 2, no. 3, pp. 327-335, 2021.

[8] A. Fuadah, A. M. Siregar and Y. Cahyana, "Model Prediksi Harga Rumah Di Kabupaten Bandung Menggunakan Multiple Linear Regression Dan Support Vector Regression," *Scientific Student Journal for Information, Technology and Science,* vol. 5, no. 2, pp. 10-16, 2024.

[9] A. A. Bastian, H. H. Handayani, D. Wahiddin and T. Rohana, "Implementasi Algoritma Support Vector Regression dan Linear Regression Untuk Prediksi Harga Rumah," *Progresif: Jurnal Ilmiah Komputer*, vol. 20, no. 2, pp. 961-972, 2024.

[10] R. K. Mariette Awad, "Chapter 4 Support Vector Regression," in *Efficient Learning Machines*, Berkeley, Apress Berkeley, CA, 2015, pp. 67-80.

[11] T. C. a. R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature," *Geoscientific Model Development*, vol. 7, no. 3, p. 247–1250, 2014.

[12] R. Bartels, Re-interpreting R-squared, regression through the origin, and weighted least squares, Australia: University of Sydney Business School, 2015.